



Shahid Beheshti
University

تحلیل داده‌های اعتباری و پیش‌بینی اعطای وام با درخت تصمیم و هرس هزینه-پیچیدگی

نام و نام خانوادگی دانشجو: مبینا امینی پارسا

رشته: علم داده ها

دانشکده: علوم ریاضی

دانشگاه: شهید بهشتی

درس: یادگیری ماشین

نام استاد: دکتر سکینه دهقان

زمستان ۱۴۰۴

فهرست مطالب

➤ مقدمه

➤ اهداف تحقیق

➤ معرفی داده‌ها

➤ پرسش یک

➤ پرسش دو

➤ نتیجه گیری

مقدمه

در سال‌های اخیر، استفاده از روش‌های یادگیری ماشین در حوزه‌های مالی و بانکی به‌طور چشمگیری افزایش یافته است. یکی از مهم‌ترین کاربردهای این روش‌ها، ارزیابی ریسک اعتباری و تصمیم‌گیری در خصوص تأیید یا رد درخواست وام متقاضیان است. فرآیند اعطای وام همواره با عدم قطعیت همراه است و تصمیم‌گیری نادرست می‌تواند منجر به افزایش مطالبات معوق و زیان مالی برای بانک‌ها شود.

در این پروژه، با استفاده از الگوریتم درخت تصمیم، مدلی برای پیش‌بینی وضعیت وام (تأیید یا رد) طراحی شده است. درخت تصمیم به دلیل ساختار سلسله‌مراتبی، قابلیت تفسیر بالا و امکان تحلیل فرآیند تصمیم‌گیری، یکی از مناسب‌ترین الگوریتم‌ها برای مسائل طبقه‌بندی در حوزه‌های مالی محسوب می‌شود.

هدف اصلی این پروژه، ساخت یک مدل پایه درخت تصمیم، ارزیابی عملکرد آن و تحلیل میزان پیچیدگی مدل در پیش‌بینی وضعیت وام متقاضیان است.

اهداف تحقیق

هدف این تحقیق، طراحی و پیاده‌سازی یک مدل طبقه‌بندی مبتنی بر درخت تصمیم به‌منظور پیش‌بینی وضعیت اعطای وام به متقاضیان بر اساس ویژگی‌های فردی و مالی آن‌ها است. در این پژوهش تلاش شده است با استفاده از الگوریتم درخت تصمیم، الگوهای مؤثر در تصمیم‌گیری اعتباری شناسایی شده و مدلی قابل تفسیر برای ارزیابی ریسک اعتباری ارائه گردد.

همچنین در این تحقیق، تأثیر پیچیدگی مدل بر عملکرد آن مورد بررسی قرار گرفته است. بدین منظور با استفاده از روش هرس هزینه-پیچیدگی و تنظیم پارامتر ccp_alpha ، تعادل مناسبی بین دقت پیش‌بینی و سادگی مدل برقرار شده است تا از بیش‌برازش جلوگیری شود و توان تعمیم‌پذیری مدل افزایش یابد.

در نهایت، هدف اصلی این مطالعه ارائه مدلی است که ضمن برخورداری از دقت بالا، ساختاری ساده و قابل تفسیر داشته باشد و بتواند در تصمیم‌گیری‌های اعتباری مورد استفاده قرار گیرد.

معرفی داده ها

در این پروژه از یک دیتاست شامل اطلاعات متقاضیان وام استفاده شده است. این داده شامل ۴۲۶۹ مشاهده و ۱۳ متغیر بوده که پس از حذف ستون شناسه، ۱۱ ویژگی برای مدل سازی مورد استفاده قرار گرفته اند.

♦ ویژگی های داده

- تعداد نمونه ها: ۴۲۶۹
- تعداد ویژگی های استفاده شده: ۱۱
- نوع مسئله: طبقه بندی دودویی

♦ متغیر هدف

نام متغیر	نوع	توضیح	مقادیر ممکن
loan_status	طبقه ای	وضعیت نهایی وام	Approved / Rejected

در فرآیند مدل سازی، این متغیر به صورت زیر کدنویسی شد:

Approved = 1

Rejected = 0

♦ ویژگی های مستقل

نام متغیر	نوع داده	توضیح	دامنه /مقادیر
loan_id	عدد صحیح	شناسه یکتای درخواست	یکتا (حذف شد)
no_of_dependents	عددی گسسته	تعداد افراد تحت تکفل	۰ تا چند نفر
education	طبقه ای	سطح تحصیلات متقاضی	Graduate / Not Graduate
self_employed	طبقه ای	وضعیت اشتغال	Yes / No
income_annum	عددی پیوسته	درآمد سالانه	مقادیر عددی
loan_amount	عددی پیوسته	مبلغ وام درخواستی	مقادیر عددی
loan_term	عددی گسسته	مدت بازپرداخت (ماه)	مقادیر عددی
cibil_score	عددی پیوسته	امتیاز اعتباری	حدود ۳۰۰ تا ۹۰۰
residential_assets_value	عددی	ارزش دارایی مسکونی	عددی
commercial_assets_value	عددی	ارزش دارایی تجاری	عددی
luxury_assets_value	عددی	ارزش دارایی لوکس	عددی
bank_asset_value	عددی	ارزش دارایی بانکی	عددی

۱. پرسش یک : آماده سازی داده و ساخت یک درخت تصمیم پایه

۱. هدف مسئله

هدف این پروژه طراحی یک مدل یادگیری ماشین برای پیش‌بینی وضعیت تأیید یا رد درخواست وام بر اساس اطلاعات مالی و فردی متقاضیان بود.

مسئله از نوع طبقه‌بندی دودویی است زیرا خروجی فقط دو حالت دارد:

• Approved

• Rejected

برای حل این مسئله از الگوریتم درخت تصمیم استفاده شد، زیرا:

- برای مسائل طبقه‌بندی مناسب است.
- قابلیت تفسیر بالا دارد (مهم در حوزه بانکی).
- نسبت به مقیاس داده حساس نیست.
- می‌تواند روابط غیرخطی را مدل کند.

الف) بارگذاری و پیش پردازش داده ها

پیش‌پردازش داده‌ها

در مرحله پیش‌پردازش داده‌ها، مجموعه‌ای از اقدامات ضروری برای آماده‌سازی داده‌ها جهت مدل‌سازی انجام شد. هدف این مرحله افزایش کیفیت داده‌ها، جلوگیری از سوگیری مدل، و فراهم کردن شرایط مناسب جهت اجرای مدل‌های مختلف بود. در ادامه، تمامی عملیات انجام‌شده همراه با دلایل انتخاب هر روش توضیح داده می‌شود.

۲. وارد کردن کتابخانه ها

در ابتدای کار کتابخانه‌های زیر وارد شدند:

- numpy و pandas برای مدیریت داده‌ها
- matplotlib و seaborn برای مصورسازی
- ابزارهای sklearn برای:

- تقسیم داده
- پیش‌پردازش
- ساخت مدل
- ارزیابی عملکرد

دلیل انجام این مرحله:

در یادگیری ماشین نیاز به ابزارهای استاندارد برای:

- خواندن داده
- پردازش
- ساخت مدل
- ارزیابی

داریم. بدون این کتابخانه‌ها امکان اجرای مراحل بعدی وجود ندارد.

۳. بارگذاری داده در محیط Google Colab

در محیط Colab فایل‌ها روی سیستم محلی هستند و باید به محیط ابری منتقل شوند.

۴. خواندن فایل داده

فایل داده را به یک DataFrame تبدیل کردیم. DataFrame ساختار جدولی دارد و امکان فیلتر، حذف ستون، بررسی نوع داده، پردازش را فراهم می‌کند.

۵. پاکسازی نام ستون‌ها

گاهی در فایل CSV فاصله اضافی در نام ستون‌ها وجود دارد که باعث خطا در دسترسی به ستون می‌شود. این کار برای جلوگیری از خطای احتمالی در مراحل بعدی انجام شد.

۶. بررسی ساختار داده با info() و بررسی داده‌های گمشده

در این مرحله بررسی شد:

- تعداد ردیف‌ها: ۴۲۶۹
- تعداد ستون‌ها: ۱۳
- نوع هر ستون
- وجود یا عدم وجود داده گمشده

مدل‌های یادگیری ماشین نمی‌توانند با مقدار Null کار کنند. اگر مقدار گمشده وجود داشت باید آن را جایگزین یا حذف می‌کردیم. نتیجه نشان داد داده کامل است و هیچ مقدار گمشده‌ای وجود نداشت و هر ۱۳ متغیر دارای ۴۲۶۹ مشاهده بودند.

۷. بررسی ردیف‌های تکراری

هیچ داده تکراری وجود نداشت. داده تکراری می‌تواند مدل را به سمت حفظ داده خاص سوق دهد و بیش‌برازش ایجاد کند.

۸. حذف ستون `loan_id`

این متغیر تنها یک شناسه است و هیچ نقش پیش‌بینی‌کننده‌ای ندارد. نگه داشتن آن ممکن است باعث شود مدل الگوهای تصادفی و بی‌معنی یاد بگیرد و درخت به شکل تصادفی بر اساس آن تقسیم کند.

۹. جدا کردن متغیر هدف از ویژگی‌ها

در یادگیری ماشین X شامل ویژگی‌ها و Y شامل خروجی مورد پیش‌بینی است. این جداسازی برای آموزش مدل ضروری است.

۱۰. تبدیل متغیر هدف به عدد

الگوریتم‌های یادگیری ماشین با متن کار نمی‌کنند. بنابراین متغیر هدف باید عددی باشد.

۱۱. بررسی توزیع کلاس‌ها

```
loan_status
1  2656
0  1613
```

اگر داده شدیداً نامتوازن باشد، `Accuracy` معیار مناسبی نخواهد بود. در اینجا عدم توازن شدید نبود.

۱۲. تفکیک متغیرهای عددی و طبقه‌ای

این کار انجام شد تا بتوان برای هر نوع داده پیش‌پردازش مناسب انجام داد. متغیر عددی باید به شکل عددی باقی بماند. متغیر متنی باید تبدیل شود.

متغیرهای عددی:

درآمد سالانه، مبلغ وام، مدت وام، امتیاز اعتباری، ارزش دارایی‌ها و...

متغیرهای طبقه‌ای:

تحصیلات، وضعیت خوداشتغالی

دلیل این تفکیک:

نوع پیش‌پردازش این دو دسته متفاوت است و نمی‌توان با هر دو یکسان رفتار کرد.

اگرچه Pipeline پیش از تقسیم داده تعریف شد، اما عملیات برازش تنها بر روی داده‌های آموزش انجام گرفت و داده آزمون صرفاً با استفاده از پارامترهای آموخته‌شده از داده آموزش تبدیل شد؛ بنابراین نشت اطلاعات رخ نداده است.

۱۳. تعریف Pipeline برای متغیرهای عددی

به دلیل طراحی مدل مقاوم برای داده‌های آینده، جلوگیری از خطا در صورت ورود داده ناقص و ساختارمند بودن Pipeline با وجود اینکه داده گم‌شده نداشتیم Imputer تعریف کردیم. همچنین چون داده‌های مالی معمولاً دارای توزیع چوله هستند و median نسبت به داده پرت مقاوم‌تر است از median استفاده کردیم.

۱۴. تعریف Pipeline برای متغیرهای طبقه‌ای

- جایگزینی با پر تکرار ترین مقدار
- OneHotEncoding

متغیرهای طبقه‌ای به متغیرهای صفر و یک تبدیل شدند. این روش برای متغیرهای دسته‌ای غیرترتیبی استفاده شد. One-Hot برای هر دسته یک ستون جدید می‌سازد و مقدار ۱/۰ تخصیص می‌دهد. مدل‌ها فقط با داده عددی کار می‌کنند. گزینه drop='first' برای جلوگیری از وابستگی خطی استفاده شد.

در این پروژه برای متغیرهای ورودی از Label Encoding استفاده نشد، زیرا در الگوریتم درخت تصمیم اگر به دسته‌ها اعداد ۰ و ۱ یا ۱ و ۲ اختصاص دهیم، ممکن است مدل آن‌ها را به صورت مقادیر عددی قابل مقایسه در نظر بگیرد و بر اساس آن‌ها شرط‌هایی مانند بزرگ‌تر از ایجاد کند. در حالی که متغیرهای طبقه‌ای ما ماهیت ترتیبی ندارند و صرفاً اسمی هستند.

به همین دلیل از One-Hot Encoding استفاده شد تا هر دسته به یک متغیر صفر و یک مستقل تبدیل شود و درخت تصمیم بدون ایجاد ترتیب مصنوعی بین دسته‌ها، فقط بر اساس وجود یا عدم وجود هر ویژگی تصمیم‌گیری کند. این کار باعث می‌شود ساختار درخت دقیق‌تر و از نظر مفهومی صحیح‌تر باشد.

استفاده از ColumnTransformer

این ابزار مشخص می کند:

- کدام ستون ها عددی هستند
- کدام ستون ها طبقه ای هستند.
- هر کدام چگونه پردازش شوند.

۱۵. تقسیم داده به Train و Test

برای جلوگیری از overfitting و ارزیابی منصفانه عملکرد مدل، داده ها به نسبت ۸۰٪ برای آموزش و ۲۰٪ برای تست تقسیم شدند. دلیل انجام این کار:

- مدل روی داده های آموزش یاد می گیرد و روی داده های دیده نشده (تست) ارزیابی می شود.
- اگر کل داده ها برای آموزش استفاده شوند، مدل روی همان داده ها بیش از حد خوب عمل می کند اما توان تعمیم به داده های جدید را از دست می دهد.
- نسبت ۲۰/۸۰ یک استاندارد رایج و مناسب برای دیتاست هایی با اندازه متوسط است.

از گزینه stratify=y برای حفظ نسبت کلاس ها در هر دو مجموعه استفاده شد. اگر این کار انجام نشود ممکن است توزیع کلاس ها در تست تست تغییر کند و ارزیابی مدل نادرست شود.

ب) آموزش درخت تصمیم با پیچیدگی محدود

در این قسمت هدف ما آموزش یک مدل طبقه بندی از نوع درخت تصمیم با پیچیدگی کنترل شده است تا:

- از بیش برازش جلوگیری شود.
- مدلی قابل تعمیم بسازیم.
- عملکرد آن را روی داده آموزش و آزمون مقایسه کنیم.

۱. درخت تصمیم

ما از الگوریتم DecisionTreeClassifier استفاده کردیم. دلیل انتخاب درخت تصمیم:

- ✓ مسئله ما طبقه‌بندی دودویی است.
- ✓ داده‌ها ترکیبی از عددی و طبقه‌ای هستند.
- ✓ درخت تصمیم نیاز به نرمال‌سازی ندارد.
- ✓ تفسیرپذیر است (برای سیستم‌های بانکی مهم است).
- ✓ می‌تواند روابط غیرخطی را یاد بگیرد.

۲. چرا پیچیدگی مدل را محدود کردیم؟

درخت تصمیم اگر بدون محدودیت رشد کند:

- ✓ تمام داده آموزش را حفظ می‌کند.
- ✓ به شدت Overfit می‌شود.
- ✓ روی داده جدید عملکرد ضعیف خواهد داشت.

به همین دلیل پارامتر زیر را تنظیم کردیم:

`max_depth = 4`

دلیل انتخاب عمق ۴:

- ✓ در عمق کم مدل ساده تر است.
- ✓ کنترل پیچیدگی
- ✓ جلوگیری از حفظ کردن داده‌ها
- ✓ ایجاد تعادل بین Bias و Variance

عمق ۴ به اندازه‌ای هست که الگوهای اصلی را یاد بگیرد ولی وارد جزئیات تصادفی نشود.

همچنین از `random_state=42` برای تکرارپذیری نتایج استفاده کردیم. درخت تصمیم هنگام ساخت ممکن است در صورت برابر بودن معیارها انتخاب تصادفی انجام دهد. با تعیین `random_state` هر بار همان درخت ساخته می‌شود.

۳. مرحله آموزش مدل

در این مرحله، مدل درخت تصمیم با عمق محدود ۴ را با استفاده از داده‌های آموزش، آموزش دادیم. با اجرای دستور `fit`، الگوریتم شروع به ساختن ساختار درخت کرد. در این فرآیند، مدل به صورت بازگشتی بهترین ویژگی‌ها و بهترین نقاط برش را انتخاب می‌کند تا داده‌ها را به شکلی تقسیم کند که خلوص هر گره بر اساس معیار `Gini` افزایش یابد. محدود کردن عمق درخت به ۴ باعث شد مدل تنها الگوهای اصلی و معنادار داده را یاد بگیرد و از رشد بیش از حد درخت و بیش‌برازش جلوگیری شود.

۴. مرحله پیش‌بینی روی داده آموزش

پس از آموزش، از مدل خواستیم روی همان داده‌های آموزشی پیش‌بینی انجام دهد. هدف از این کار بررسی میزان یادگیری مدل از داده‌هایی بود که در اختیار داشته است. اگر دقت در این مرحله بسیار پایین باشد، نشان‌دهنده `Underfitting` است و اگر بسیار بالا ولی در تست پایین باشد، نشانه `Overfitting` خواهد بود. بنابراین این مرحله به ما کمک می‌کند کیفیت یادگیری مدل را ارزیابی اولیه کنیم.

۵. مرحله پیش‌بینی روی داده آزمون

در نهایت، مدل روی داده‌های آزمون (که در فرآیند آموزش دیده نشده‌اند) پیش‌بینی انجام داد. این مرحله مهم‌ترین معیار ارزیابی عملکرد واقعی مدل است، زیرا نشان می‌دهد مدل تا چه حد توانایی تعمیم به داده‌های جدید و ناشناخته را دارد. مقایسه دقت آموزش و آزمون مشخص می‌کند که آیا مدل دچار بیش‌برازش شده است یا خیر.

۶. دقت مدل روی داده آموزش و آزمون

نتایج بدست آمده:

دقت آموزش: ۰.۹۶۸۶۶۷۶۴۲۷۵۲۵۶۲۲



دقت آزمون: ۰.۹۷۰۷۲۵۹۹۵۳۱۶۱۵۹۲

۷. ماتریس درهم ریختگی و Classification Report برای داده آزمون

Classification Report:

	precision	recall	f1-score	support
0	1.00	0.92	0.96	323
1	0.96	1.00	0.98	531
accuracy			0.97	854
macro avg	0.98	0.96	0.97	854
weighted avg	0.97	0.97	0.97	854

Confusion Matrix with Percentages



برای ارزیابی عملکرد مدل در داده آزمون، از سه نوع ماتریس درهم‌ریختگی نسخه عددی، نسخه درصدی و نسخه رنگی و همچنین گزارش طبقه‌بندی استفاده شد. ترکیب این نتایج تصویری دقیق و جامع از رفتار مدل ارائه می‌دهد.

در ماتریس درهم‌ریختگی عددی، مدل توانسته است 298 نمونه از کلاس Rejected را به‌درستی تشخیص دهد و تنها 25 نمونه از این کلاس را به اشتباه در کلاس Approved قرار دهد. در مقابل برای کلاس Approved مدل عملکردی کاملاً بی‌خطا داشته و 531 نمونه را به‌درستی تشخیص داده و هیچ نمونه‌ای را اشتباه رد نکرده است. این مقادیر چهار حالت اصلی ماتریس را تشکیل می‌دهند:

مقدار	توضیح	نوع پیش‌بینی
۲۹۸	پیش‌بینی درست Rejected	True Negative (TN)
۲۵	پیش‌بینی اشتباه Approved برای نمونه Rejected	False Positive (FP)
۰	پیش‌بینی اشتباه Rejected برای نمونه Approved	False Negative (FN)
۵۳۱	پیش‌بینی درست Approved	True Positive (TP)

نسخه درصدی ماتریس این الگو را شفاف‌تر می‌کند. برای کلاس Rejected مدل 92.3٪ از نمونه‌ها را درست تشخیص داده و 7.7٪ خطا داشته است. برای کلاس Approved مدل 100٪ Recall داشته و هیچ نمونه‌ای را از دست نداده است. این درصدها نشان می‌دهند که مدل در تشخیص کلاس Approved عملکردی کاملاً پایدار دارد و تنها چالش آن، اشتباه گرفتن بخشی از نمونه‌های Rejected است.

در ماتریس Heatmap رنگی، شدت رنگ‌ها نیز همین الگو را تأیید می‌کند. خانه مربوط به TP با رنگ زرد بسیار روشن نمایش داده شده که نشان‌دهنده بیشترین تعداد نمونه صحیح است. خانه TN با رنگ سبز-آبی نشان می‌دهد تعداد این پیش‌بینی‌ها نیز زیاد است، اما کمتر از TP. خانه‌های FP و FN با رنگ‌های بنفش تیره و بسیار تیره نمایش داده شده‌اند که بیانگر تعداد کم خطاها هستند. این طیف رنگی کمک می‌کند بدون نگاه به اعداد، به‌سرعت تشخیص دهیم مدل در کدام بخش‌ها عملکرد قوی‌تری داشته است.

گزارش طبقه‌بندی نیز این نتایج را تأیید می‌کند. برای کلاس Rejected مقدار $Precision = 1.00$ نشان می‌دهد هر نمونه‌ای که مدل به‌عنوان رد شده پیش‌بینی کرده، واقعاً رد شده بوده است. مقدار $Recall = 0.92$ همان ۷.۷٪ خطا را منعکس می‌کند. برای کلاس Approved مقدار $Recall = 1.00$ نشان‌دهنده تشخیص

کامل این کلاس است و $Precision = 0.96$ نشان می‌دهد تنها درصد کمی از پیش‌بینی‌های Approved اشتباه بوده‌اند. مقادیر $F1\text{-score}$ برای هر دو کلاس (0.96 و 0.98) نیز نشان‌دهنده تعادل بسیار خوب بین Precision و Recall است. مقدار $Accuracy = 0.97$ و میانگین‌های Macro و Weighted که هر دو برابر 0.97 هستند، نشان می‌دهند مدل در مجموع عملکردی بسیار قوی دارد.

این مجموعه تحلیل‌ها نشان می‌دهد مدل در تشخیص کلاس Approved تقریباً بی‌نقص است و تنها خطای قابل توجه آن مربوط به بخشی از نمونه‌های Rejected است که به اشتباه Approved شده‌اند. با این حال عملکرد کلی مدل بسیار پایدار، دقیق و قابل اعتماد است.

۸. تحلیل عمق و تعداد گره‌های درخت تصمیم و برداشت آن‌ها از پیچیدگی مدل

عمق واقعی درخت: ۴

تعداد گره‌ها: ۲۱

- تعداد گره‌های داخلی: ۱۰


- تعداد گره‌های برگ: ۱۱

پس از آموزش مدل درخت تصمیم با محدودیت $\text{max_depth} = 4$ ، ساختار نهایی درخت نشان می‌دهد که عمق واقعی آن برابر با ۴ و تعداد کل گره‌ها برابر با ۲۱ است. عمق درخت بیانگر طولانی‌ترین مسیر از ریشه تا یک برگ است و زمانی که عمق ۴ به دست می‌آید، یعنی مدل برای رسیدن به نتیجه نهایی حداکثر چهار مرحله تصمیم‌گیری متوالی را طی می‌کند؛ به این معنا که برای هر پیش‌بینی نهایتاً چهار سؤال شرطی مانند «آیا درآمد بیشتر از مقدار مشخص است» بررسی می‌شود. چنین عمقی نشان‌دهنده سادگی نسبی مدل است، زیرا هرچه عمق کمتر باشد مدل قابل‌تفسیرتر و کنترل‌شده‌تر خواهد بود، در حالی که عمق زیاد معمولاً به پیچیدگی بیش از حد و خطر بیش‌برازش منجر می‌شود. بنابراین عمق ۴ کاملاً با هدف جلوگیری از **Overfitting** هم‌راستا است و نشان می‌دهد که مدل اجازه رشد بی‌رویه پیدا نکرده است.

از طرف دیگر، تعداد ۲۱ گره در ساختار درخت نشان می‌دهد که مدل تعداد محدودی تقسیم انجام داده و شاخه‌های آن بیش از حد گسترده نشده‌اند. هر گره در درخت یا یک گره تصمیم است که داده را تقسیم می‌کند یا یک برگ که پیش‌بینی نهایی را ارائه می‌دهد. اگر تعداد گره‌ها بسیار زیاد بود، مثلاً صدها گره، این موضوع

نشانه‌ای از پیچیدگی بیش از حد، حفظ جزئیات داده‌های آموزش و کاهش تعمیم‌پذیری مدل بود، اما در اینجا تعداد گره‌ها متعادل است و نشان می‌دهد مدل نه ساده و ناکارآمد است و نه بیش از حد پیچیده.

با توجه به عمق محدود ۴، تعداد گره‌های ۲۱ و نزدیکی دقت آموزش و آزمون، می‌توان نتیجه گرفت که مدل در سطح مناسبی از پیچیدگی قرار دارد. این ساختار نشان می‌دهد که مدل نه دچار Underfitting شده و نه Overfitting، بلکه تعادلی مطلوب میان Bias و Variance برقرار کرده است. در مجموع، این اعداد تأیید می‌کنند که مدل هم قابل تفسیر است هم از نظر عملکردی پایدار و قابل اعتماد.



شکل زیر ساختار نهایی درخت تصمیم آموزش داده‌شده را نشان می‌دهد. همان‌طور که مشاهده می‌شود، درخت دارای عمق محدود و تعداد گره‌های کنترل‌شده است که این موضوع با تحلیل قبلی ما درباره جلوگیری از بیش‌برازش کاملاً همخوانی دارد. در ریشه درخت، ویژگی `num_cibil_score` قرار گرفته که نشان می‌دهد این متغیر با مرز 549.5 بیشترین نقش را در تفکیک اولیه داده‌ها داشته است. در شاخه‌های بعدی نیز ویژگی‌هایی مانند `num_loan_term`، `num_loan_amount`، `residential_assets_value` و `num_income_amount` به‌عنوان عوامل کلیدی تصمیم‌گیری استفاده شده‌اند.

در سمت راست درخت، بیشتر مسیرها به کلاس Approved ختم می‌شوند که با نتایج ماتریس درهم‌ریختگی نیز سازگار است؛ جایی که مدل تقریباً تمام نمونه‌های Approved را به درستی تشخیص داده بود. در سمت چپ درخت، برخی مسیرها به Approved و برخی به Rejected ختم می‌شوند که این نیز با خطاهای مشاهده‌شده در ماتریس False Positive های مربوط به کلاس Rejected مطابقت دارد. مقادیرهای Gini پایین در بسیاری از گره‌ها نشان‌دهنده خلوص بالا و تصمیم‌گیری مطمئن مدل در آن نقاط است.

به‌طور کلی، ساختار درخت نشان می‌دهد مدل با استفاده از تعداد محدودی تقسیم، توانسته است الگوی تصمیم‌گیری قابل‌تفسیر و مؤثری ایجاد کند که با نتایج عملکردی مدل ($\text{Accuracy} = 0.97$) کاملاً سازگار است.

۹. تحلیل نتایج Cross-Validation

Cross Validation Scores:

[0.96955504 0.96135831 0.96604215 0.96018735 0.96365768]

Mean Accuracy:

0.964160107184726

Standard Deviation:

0.0033625169457247367

این نتایج نشان می‌دهند که مدل در تمام فولدها عملکردی بسیار پایدار و نزدیک به هم داشته است. مقدار میانگین دقت برابر با 96.4% است که نشان‌دهنده توانایی بالای مدل در یادگیری الگوهای داده و تعمیم آن‌ها به داده‌های جدید است. همچنین مقدار انحراف معیار بسیار پایین (0.0033) بیانگر این است که مدل نسبت به تغییرات داده در هر فولد حساسیت کمی دارد و عملکرد آن دچار نوسان قابل توجه نمی‌شود.

به‌طور کلی، این نتایج تأیید می‌کنند که مدل نه تنها روی داده آزمون عملکرد خوبی داشته، بلکه در ارزیابی چندبخشی نیز پایدار، قابل اعتماد و بدون نشانه‌ای از بیش‌برازش است. این موضوع با سایر شاخص‌های ارزیابی

Confusion Matrix و Classification Report نیز همخوانی دارد و نشان می‌دهد مدل انتخاب‌شده از نظر دقت و ثبات، گزینه‌ای مناسب برای مسئله طبقه‌بندی حاضر است.

۲. پرسش دو: اثر پیچیدگی مدل و هرس درخت


۱. هدف مسئله

بررسی رفتار درخت در حالت‌های پیچیده تر و سپس کنترل پیچیدگی با هرس است.

الف) آموزش درخت بدون محدودیت عمق

در این مرحله، یک مدل درخت تصمیم بدون هیچ محدودیتی در عمق آموزش داده شد تا مشخص شود درختی که اجازه دارد تا هر اندازه رشد کند چه رفتاری از خود نشان می‌دهد. در این حالت، مدل می‌تواند داده‌ها را آن قدر تقسیم کند که تقریباً هر نمونه آموزشی در یک برگ جداگانه قرار بگیرد.

پس از آموزش مدل، نتایج زیر به دست آمد:



Train Accuracy: 1.0

Test Accuracy: 0.9836065573770492

Tree Depth: 15

Number of Nodes: 105

در مدل بدون محدودیت عمق، دقت آموزش به عدد کامل ۱۰۰ درصد رسیده است. این نتیجه نشان می‌دهد که درخت تمام جزئیات و حتی نویزهای موجود در داده آموزش را یاد گرفته و عملاً داده‌ها را حفظ کرده است. هرچند دقت مدل روی داده آزمون نیز همچنان بالا و حدود ۹۸ درصد است، اما مقایسه این مدل با درختی که عمق آن ۴ و تعداد گره‌هایش ۲۱ بود نشان می‌دهد که درخت کامل بسیار پیچیده‌تر شده است. عمق ۱۵ و وجود ۱۰۵ گره بیانگر این است که مدل به جای یادگیری الگوهای کلی، وارد جزئیات ریز و خاص داده‌ها شده است.

این رفتار همان بیش‌برازش است، حالتی که مدل به تفاوت‌های کوچک و تصادفی داده‌ها وابسته می‌شود و نسبت به تغییرات جزئی در داده‌های جدید حساسیت زیادی پیدا می‌کند. در نتیجه، هرچند دقت آزمون هنوز خوب است، اما پایداری مدل کاهش می‌یابد و احتمال افت عملکرد در مواجهه با داده‌های واقعی بیشتر می‌شود. به همین دلیل، محدود کردن عمق درخت یا استفاده از تنظیمات کنترلی دیگر برای جلوگیری از پیچیدگی بیش از حد ضروری است.

از نظر اریبی و واریانس نیز تفاوت دو مدل کاملاً مشخص است. مدل با عمق ۴ به دلیل سادگی، اریبی کمی بالاتر و واریانس پایین‌تری دارد و همین باعث می‌شود پایدارتر و قابل‌اعتمادتر باشد. در مقابل، درخت بدون محدودیت عمق با اریبی بسیار پایین و واریانس بالا عمل می‌کند، زیرا تقریباً تمام جزئیات داده حتی نویزها را یاد می‌گیرد. این واریانس بالا همان عامل اصلی بیش‌برازش است.


با اینکه دقت آزمون مدل پیچیده تنها حدود ۲ درصد بهتر از مدل ساده‌تر است اما این اختلاف ناچیز در برابر افزایش شدید پیچیدگی مدل منطقی نیست. بنابراین، مدل ساده‌تر با عمق ۴ تعادل بهتری میان اریبی و واریانس برقرار کرده و برای تعمیم به داده‌های جدید مناسب‌تر است.

ب) بررسی رفتار مدل در عمق های متفاوت

در این بخش، درخت تصمیم با چهار مقدار متفاوت برای عمق شامل ۳، ۵، ۱۰ و بدون محدودیت آموزش داده شد تا رفتار مدل از نظر دقت و همچنین الگوی Bias-Variance بررسی شود. برای هر عمق، دقت مدل روی داده های آموزش و آزمون محاسبه شد. نتایج به دست آمده در جدول زیر آمده است:

Tree Depth	Train Accuracy	Test Accuracy
3	0.9625	0.9719
5	0.9742	0.9684
10	0.9950	0.9801
Unlimited	1.0000	0.9836

برای نمایش بهتر روند تغییرات، نموداری از دقت آموزش و آزمون نسبت به عمق رسم شد. این نمودار نشان می دهد که با افزایش عمق، مدل به تدریج پیچیده تر می شود و رفتار آن از نظر Bias-Variance تغییر می کند.



در عمق ۳، هر دو دقت آموزش و آزمون نسبتاً پایین تر هستند. این بخش از نمودار معمولاً با رنگ **صورتی** مشخص می شود که نشان دهنده کم برآزش است. در این حالت، مدل بیش از حد ساده است و نمی تواند الگوهای کافی از داده را یاد بگیرد. این وضعیت با اریبی بالا و واریانس پایین همراه است.

در عمق ۵، مدل به تعادل بهتری می رسد. دقت آموزش و آزمون به هم نزدیک اند و مدل نه بیش از حد ساده است و نه بیش از حد پیچیده. این نقطه معمولاً بهترین توازن بین اریبی و واریانس را ایجاد می کند و در نمودار در ناحیه میانی قرار می گیرد.

در عمق ۱۰، دقت آموزش به طور قابل توجهی افزایش یافته و به حدود ۰.۹۹۵ رسیده است. دقت آزمون نیز همچنان بالا است. این بخش نشان می دهد که مدل در حال حرکت به سمت پیچیدگی بیشتر است، اما هنوز وارد ناحیه بیش برآزش شدید نشده است. فاصله بین دقت آموزش و آزمون کمی بیشتر می شود که نشانه افزایش واریانس است.

در حالت **بدون محدودیت عمق**، مدل به دقت آموزش ۱۰۰ درصد می رسد. این بخش از نمودار معمولاً با رنگ **زرد** مشخص می شود که نشان دهنده بیش برآزش است. در این حالت، مدل تقریباً تمام جزئیات و حتی نویزهای داده آموزش را یاد گرفته است. هر چند دقت آزمون هنوز بالا است (۰.۹۸۳۶)، اما فاصله بین دقت آموزش و آزمون و همچنین رشد شدید تعداد گره ها نشان می دهد که مدل دارای واریانس بالا و اریبی بسیار پایین است. این حساسیت زیاد نسبت به تغییرات کوچک در داده ها، همان نشانه اصلی بیش برآزش است.

ج) کاهش پیچیدگی با Cost-Complexity Pruning

در این بخش، هدف کنترل پیچیدگی درخت تصمیم و جلوگیری از بیش برآزش بود. همان طور که در بخش های قبل مشاهده شد، درخت کامل (بدون محدودیت عمق) به دقت آموزش بسیار بالا (تقریباً برابر ۱) دست می یابد که نشان دهنده برآزش کامل داده های آموزشی است. با این حال، مدل های بسیار پیچیده ممکن است الگوهای تصادفی یا نویز موجود در داده را نیز یاد بگیرند که این موضوع می تواند تعمیم پذیری مدل را کاهش دهد.

به همین منظور از روش هرس پسین مبتنی بر پارامتر ccp_alpha استفاده شد. این روش با افزودن یک جمله جریمه به تابع هزینه، گره های کم اهمیت را حذف کرده و ساختار درخت را ساده تر می کند.


ابتدا با استفاده از تابع `cost_complexity_pruning_path` مجموعه‌ای از مقادیر ممکن برای `ccp_alpha` استخراج شد. این مقادیر نشان‌دهنده سطوح مختلف هرس درخت هستند. تنها مقادیر مثبت `alpha` در نظر گرفته شدند، زیرا مقدار صفر معادل درخت کامل بدون هرس است.

سپس برای هر مقدار `ccp_alpha` یک درخت تصمیم جدید آموزش داده شد و برای هر مدل:

- دقت آموزش
- دقت آزمون
- عمق درخت
- تعداد کل گره‌ها

محاسبه و ثبت گردید.

به منظور تحلیل رفتار مدل، نمودار تغییرات دقت آموزش و آزمون بر حسب `ccp_alpha` (در مقیاس لگاریتمی) رسم شد. این نمودار نشان داد که با افزایش مقدار `alpha`، پیچیدگی درخت کاهش یافته و در مقادیر بزرگ‌تر، دقت آزمون نیز کاهش محسوسی پیدا می‌کند که نشان‌دهنده کم‌برازش است.



برای بررسی اثر هرس کردن درخت تصمیم، مدل با مقادیر مختلف پارامتر `ccp_alpha` آموزش داده شد. این پارامتر میزان جریمه پیچیدگی درخت را کنترل می‌کند؛ هرچه مقدار آن بیشتر باشد، درخت ساده‌تر و کوچک‌تر می‌شود. دقت آموزش و آزمون برای مقادیر مختلف `ccp_alpha` محاسبه شد و نموداری از تغییرات دقت‌ها رسم گردید.

نمودار نشان می‌دهد که در مقادیر بسیار کوچک `ccp_alpha`، درخت تقریباً بدون هرس باقی می‌ماند و دقت آموزش و آزمون هر دو بالا هستند. با افزایش `ccp_alpha`، درخت ساده‌تر می‌شود و دقت‌ها به تدریج کاهش می‌یابند. در مقادیر بزرگ، افت دقت شدیدتر است و مدل توانایی یادگیری الگوهای اصلی داده را از دست می‌دهد.

معيار انتخاب مقدار بهينه `ccp_alpha`

برای انتخاب مقدار مناسب `alpha`، صرفاً بیشترین دقت آزمون در نظر گرفته نشد؛ زیرا این انتخاب ممکن است همچنان منجر به مدلی نسبتاً پیچیده شود. در عوض، مقداری انتخاب شد که:

- نسبت به درخت کامل کاهش معناداری در عمق و تعداد گره‌ها ایجاد کند،
 - و در عین حال افت قابل توجهی در دقت آزمون مشاهده نشود.
- بر اساس نمودار و نتایج به دست آمده، مقدار α در حدود ۰.۰۰۱ انتخاب شد، زیرا در این نقطه کاهش قابل توجهی در عمق درخت (از ۱۵ به ۱۰) و تعداد گره‌ها مشاهده می‌شود.
- بر اساس این معیار، مقدار زیر انتخاب شد:


- `ccp_alpha = 0.00103`
- `Train Accuracy = 0.9889`
- `Test Accuracy = 0.9859`
- `Tree Depth = 10`
- `Number of Nodes = 29`

در مقایسه با درخت کامل (عمق ۱۵ و ۱۰۵ گره)، این مدل کاهش قابل توجهی در پیچیدگی داشته است، در حالی که افت دقت آزمون کمتر از ۰.۳٪ بوده و فاصله بین دقت آموزش و آزمون نیز کاهش یافته است. این

موضوع نشان می‌دهد که هرس انجام‌شده توانسته است تعادل مناسبی بین سادگی مدل و توان تعمیم برقرار کند.

Best Alpha Value	0.001
Train Accuracy	0.9889
Test Accuracy	0.9859
Tree Depth	10
Total Nodes	29
Internal Nodes	14
Leaf Nodes	15

Decision Tree with ccp_alpha = 0.0010329240440124024



د) جمع بندی نهایی

Metric	Tree with Depth 4	Pruned Tree with $\alpha = 0.00103$	Unlimited Tree (Full Tree)
Train Accuracy	0.9687	0.9889	1
Test Accuracy	0.9707	0.9859	0.9836
Tree Depth	4	10	15
Total Nodes	21	29	105
Internal Nodes	10	14	52
Leaf Nodes	11	15	53

در این آزمایش سه مدل مختلف درخت تصمیم بررسی شدند: یک درخت با عمق محدود، یک درخت کامل بدون هرس، و یک درخت هرس شده با مقدار بهینه α . مقایسه این سه مدل نشان می‌دهد که هر یک از آن‌ها ویژگی‌های متفاوتی از نظر دقت، تعمیم‌پذیری و تفسیرپذیری دارند.

مدل اول که عمق آن به ۴ محدود شده بود، ساده‌ترین ساختار را داشت و تنها شامل ۲۱ گره بود. این مدل با وجود سادگی، دقت قابل قبولی روی داده آزمون (حدود ۰.۹۷) ارائه داد. به دلیل پیچیدگی کم، این مدل از نظر تفسیرپذیری بسیار مناسب است و تعادل خوبی بین سادگی و عملکرد ایجاد می‌کند. با این حال، به دلیل محدودیت عمق، کمی دچار کم‌برازش است و بخشی از الگوهای پیچیده‌تر داده را نمی‌تواند یاد بگیرد.

مدل دوم، یعنی درخت کامل بدون هرس، بیشترین پیچیدگی را داشت و با ۱۰۵ گره و عمق ۱۵ تقریباً تمام جزئیات داده آموزش را یاد گرفته بود. این مدل دقت آموزش ۱۰۰ درصدی دارد که نشانه واضح بیش‌برازش است. هرچند دقت آزمون آن نسبتاً بالا است (حدود ۰.۹۸۳۶)، اما فاصله زیاد بین دقت آموزش و آزمون و همچنین اندازه بسیار بزرگ درخت نشان می‌دهد که تعمیم‌پذیری آن پایین‌تر است. علاوه بر این، تفسیر چنین درخت بزرگی دشوار است.

مدل سوم، یعنی درخت هرس شده با مقدار α بهینه (حدود ۰.۰۰۱۰۳)، تعادلی مناسب بین دو مدل قبلی ایجاد می‌کند. این مدل با ۲۹ گره و عمق ۱۰ بسیار کوچک‌تر از درخت کامل است اما همچنان توانسته دقت آزمون

بالا تری نسبت به هر دو مدل دیگر به دست آورد (حدود ۰.۹۸۵۹). این مدل نه بیش از حد ساده است و نه بیش از حد پیچیده، و از نظر Bias-Variance در نقطه بهینه قرار دارد. همچنین تفسیرپذیری آن نسبت به درخت کامل بسیار بهتر است.

به طور کلی، نتایج نشان می‌دهد که:

- درخت با عمق محدود: ساده، قابل تفسیر، اما کمی کم‌برازش
- درخت کامل بدون هرس: بسیار دقیق روی آموزش، اما بیش‌برازش و کم‌تعمیم‌پذیر
- درخت هرس‌شده: بهترین تعادل بین دقت، تعمیم‌پذیری و تفسیرپذیری

نتیجه گیری

بنابراین از نظر دقت آموزش، هرچه درخت عمیق‌تر و پیچیده‌تر شود، دقت افزایش می‌یابد؛ به‌طوری‌که درخت بدون محدودیت به دقت ۱۰۰ درصد می‌رسد. این موضوع نشان‌دهندهٔ بیش‌برازش است، زیرا مدل به‌جای یادگیری الگوهای کلی، جزئیات و نویز داده را نیز حفظ می‌کند.

از نظر تفسیرپذیری، درخت کامل به دلیل تعداد گره‌های زیاد قابل استفاده نیست، در حالی که درخت با عمق ۴ و درخت هرس‌شده ساختار ساده‌تری دارند و تحلیل آن‌ها آسان‌تر است.

از نظر تعمیم‌پذیری نیز درخت بدون محدودیت عملکرد ضعیف‌تری دارد، در حالی که درخت با عمق ۴ و مدل هرس‌شده هر دو تعادل مناسبی بین اریبی و واریانس برقرار کرده‌اند. با این حال، مدل هرس‌شده به دلیل دقت بالاتر و پیچیدگی کنترل‌شده، بهترین گزینه در میان سه مدل محسوب می‌شود.